CC3084 · DATA SCIENCE · UVG · 12.10.2026

MOSQUITOS

EN IMÁGENES CIUDADANAS

MosquitoAlert Challenge 2023 · Reto 17

ENCONTRAR Y NOMBRAR AL MOSQUITO

10,354

imágenes limpias, de 10,357 originales

6

clases: 2 especies, 3 géneros y 1 complejo de especies

98 : 1

entre la clase más grande y la más pequeña

Ae. aegypti | Ae. albopictus | Anopheles | Culex | Culiseta | Ae. japonicus/koreicus

Fotos de celular, un mosquito pequeño por foto. Se mide con **F1 macro**, y la caja predicha debe tener **IoU ≥ 0.75** con la real (Mosquito Alert Team y AIcrowd, 2023).

OBJETIVOS DEL PROYECTO

OBJETIVO GENERAL

Desarrollar un modelo para la localización y clasificación automatizada de seis especies y géneros de mosquitos vectores a partir de fotografías de ciencia ciudadana, evaluando estrategias para mitigar el desbalance de clases y la variabilidad visual.

01 Analizar el desbalance de clases para saber qué especies tienen pocas imágenes.

02 Evaluar la calidad y la variación de las imágenes (tamaños, iluminación) para definir el aumento de datos.

03 Construir y evaluar un modelo base que mida la precisión inicial en las seis clases.

LO QUE DICE LA LITERATURA

DOS ETAPAS

Detectar y luego clasificar rindió más que una sola etapa. Kittichai et al. (2021)

TRANSFERENCIA

Las CNN preentrenadas son lo habitual con mosquitos. Motta et al. (2020); Ong et al. (2021)

DINOV2

Características generales sin ajuste fino, útiles con pocos datos. Oquab et al. (2024)

DESBALANCE

El sobremuestreo funcionó mejor, hasta equilibrar las clases. Buda et al. (2018)

JERARQUÍA

Clasificar por niveles taxonómicos. Silla y Freitas (2011)

EL HUECO

No encontramos una comparación plana contra jerárquica en mosquitos. La hacemos aquí.

LOS DATOS

10,357

imágenes originales de train.csv

10,354

tras descartar 3 cajas inválidas

Dato	Valor
Variables	8: nombre, ancho, alto, 4 coordenadas de la caja y clase
Caja	1 por imagen, anotada por entomólogos
Nulos y duplicados	0 y 0
Ancho de las fotos	139 a 9,280 px
Peso total	≈ 9 GB

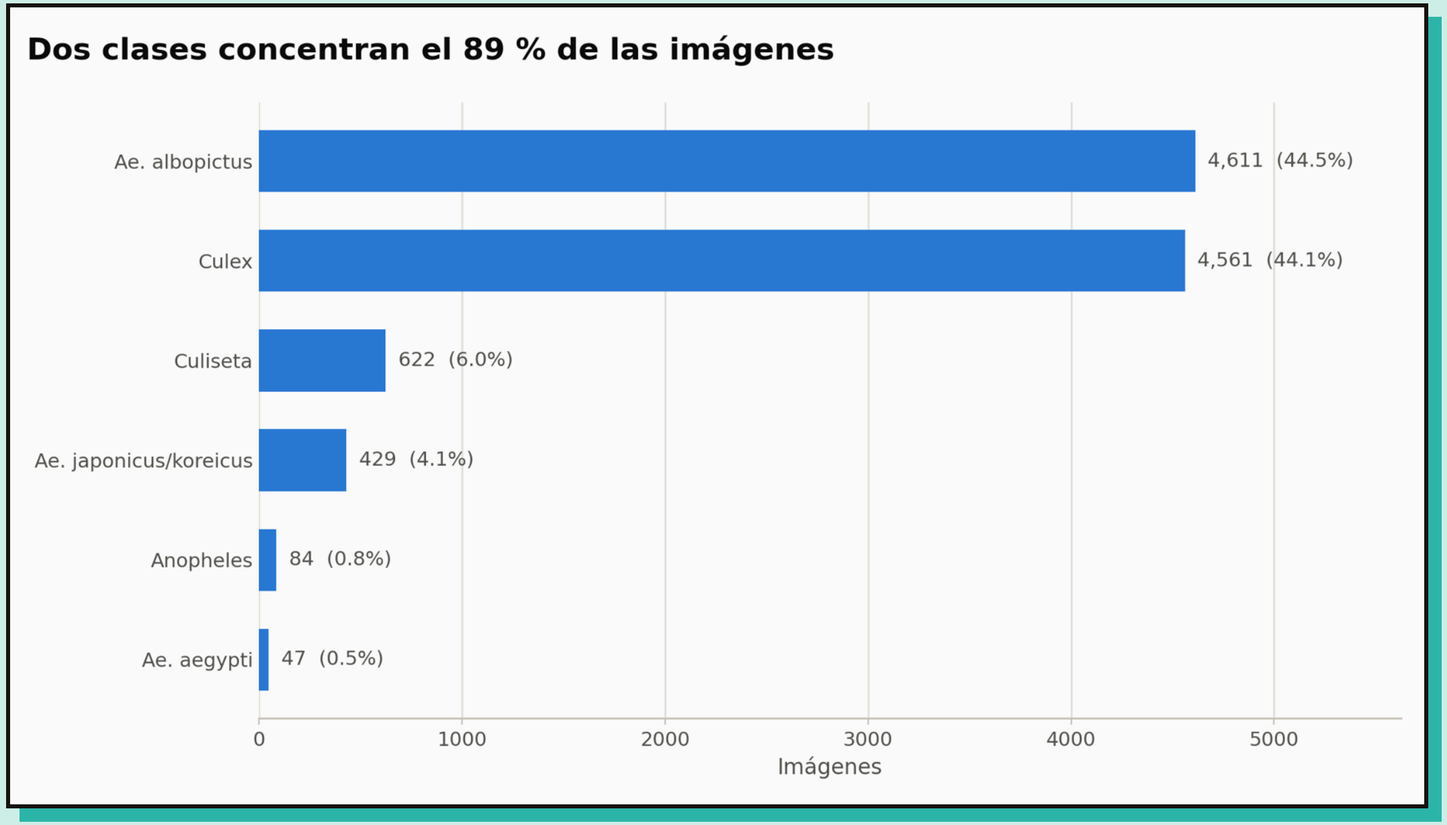
DESBALANCE DE CLASES

98 : 1

albopictus (4,611) contra aegypti (47)

Albopictus y Culex suman 88.6 % de las imágenes. Aegypti, 0.45 %.

Métrica del reto: F1 macro.



LAS FOTOS CIUDADANAS

7.3 %

mediana del área de la foto que ocupa el mosquito (media: 13.1 %)

139–9,280

píxeles de ancho entre las fotos

28.5 %

área media de A. aegypti en la foto; albopictus y Culex: 12–13 %

Atípicos: 729 fotos (7 %), conservadas por ser macros legítimas. Se compensan con recorte con margen y aumento de datos.

DOS ETAPAS, UN RECORTE EN MEDIO

01
FOTO
Imagen de celular, de 139 a 9,280 px

02
DETECTOR
YOLOv8n de una sola clase: «mosquito» (Terven et al., 2023)

03
RECORTE
Caja con 15 % de margen, a 256 × 256 px

04
CLASIFICADOR
Seis modelos comparados con F1 macro

PARTICIÓN ESTRATIFICADA · SEMILLA 42

ENTRENAMIENTO 70 %	VAL 15 %	PRUEBA 15 %
7,248 imágenes	1,553	1,553

Partición antes de sobremuestrear, para no filtrar copias entre grupos (Buda et al., 2018).

DETECTOR YOLOV8N

0.979

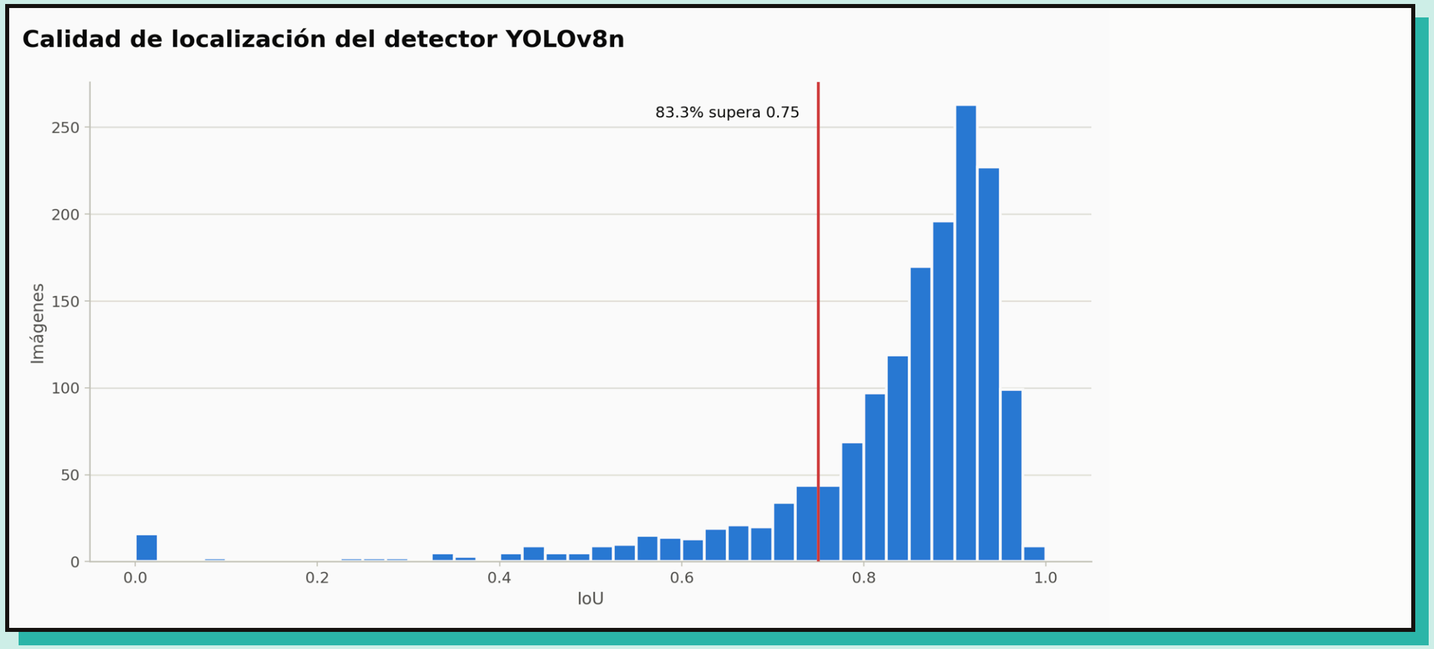
mAP@50 en prueba (mAP@50-95: 0.723)

0.831

IoU medio de la caja de mayor confianza

83.3 %

de las 1,553 fotos de prueba con IoU ≥ 0.75, el umbral del reto



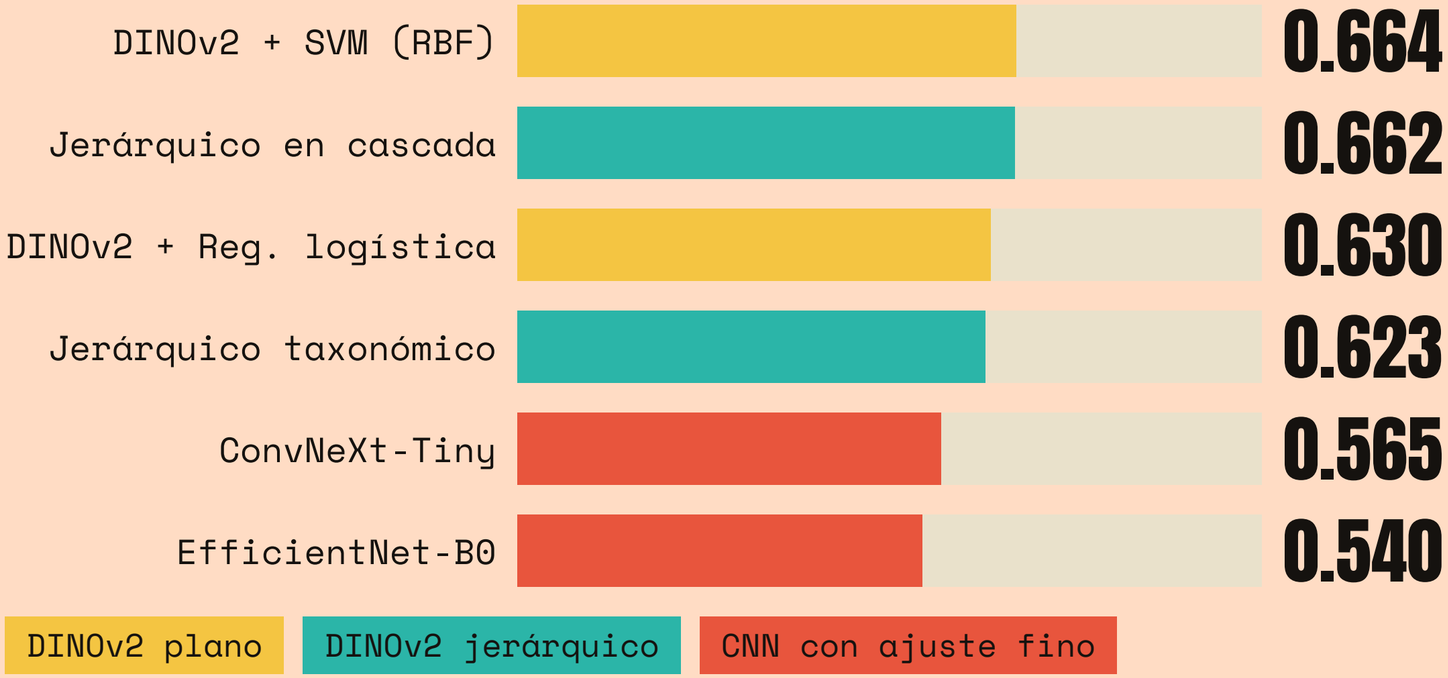
YOLOv8n preentrenado en COCO · 512 px · 6 épocas · 20 min · 32.5 ms por imagen

SEIS CLASIFICADORES

Modelo	Familia	Ajuste elegido	Min	ms/img
DINOv2 + SVM (RBF)	DINOv2 congelado, plano	C = 10	1.9	37.3
Jerárquico en cascada	DINOv2 congelado, 2 niveles	C = 0.1	0.16	36.0
DINOv2 + Reg. logística	DINOv2 congelado, plano	C = 0.1	0.13	36.0
Jerárquico taxonómico	DINOv2 congelado, 2 niveles	C = 0.1	0.26	36.0
ConvNeXt-Tiny	CNN, ajuste fino	3 épocas, 176 px, lr 3e-4	17.6	19.9
EfficientNet-B0	CNN, ajuste fino	6 épocas, 224 px, lr 5e-4	8.7	12.3

Min: minutos de entrenamiento · ms/img: inferencia por imagen · DINOv2: 384 características congeladas

RESULTADOS EN PRUEBA



EXACTITUD DEL MEJOR MODELO

0.940

de exactitud, contra 0.664 de F1 macro.

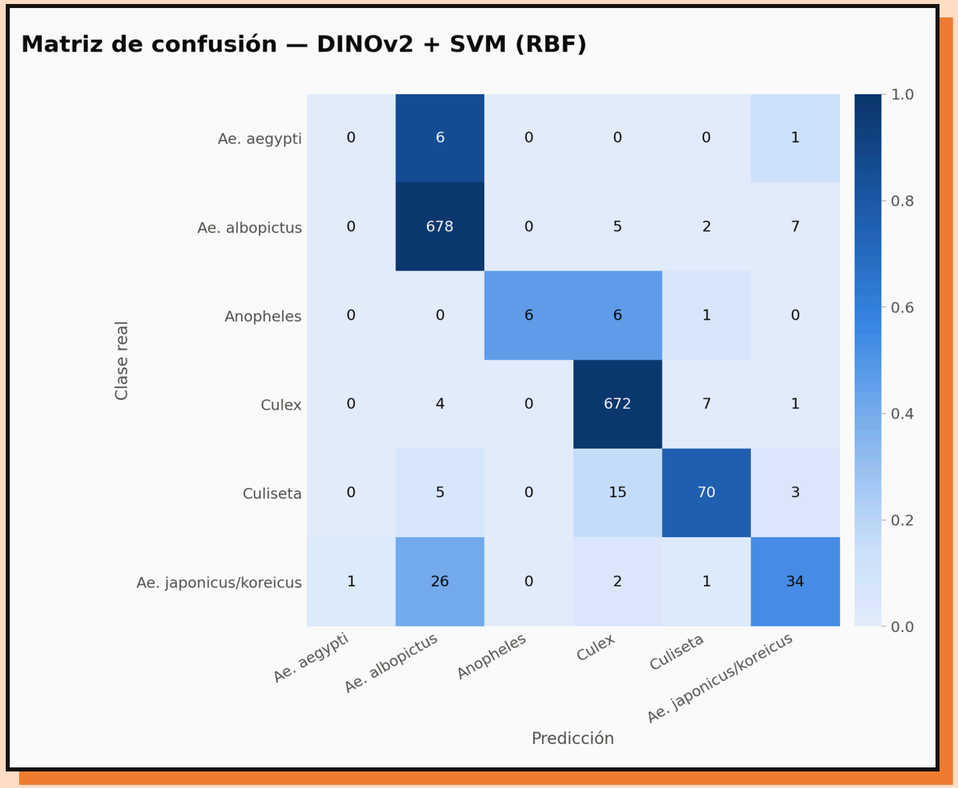
88.6 % de las fotos de prueba son albopictus o Culex.

F1 POR CLASE

	albopictus n = 3,227	Culex n = 3,193	Culiseta n = 436	japonicus / koreicus n = 301	Anopheles n = 58	aegypti n = 33
DINOv2 + SVM (RBF)	0.96	0.97	0.80	0.62	0.63	0.00
Jerárquico en cascada	0.94	0.95	0.74	0.57	0.67	0.11
DINOv2 + Reg. logística	0.93	0.95	0.79	0.53	0.58	0.00
Jerárquico taxonómico	0.92	0.95	0.76	0.51	0.59	0.00
ConvNeXt-Tiny	0.95	0.94	0.64	0.56	0.30	0.00
EfficientNet-B0	0.92	0.94	0.67	0.53	0.19	0.00

Aegypti: 7 fotos de prueba; solo la cascada acierta una (borde azul).

MATRIZ DE CONFUSIÓN



DINOV2 + SVM · PRUEBA

6 de 7 aegypti terminan como albopictus

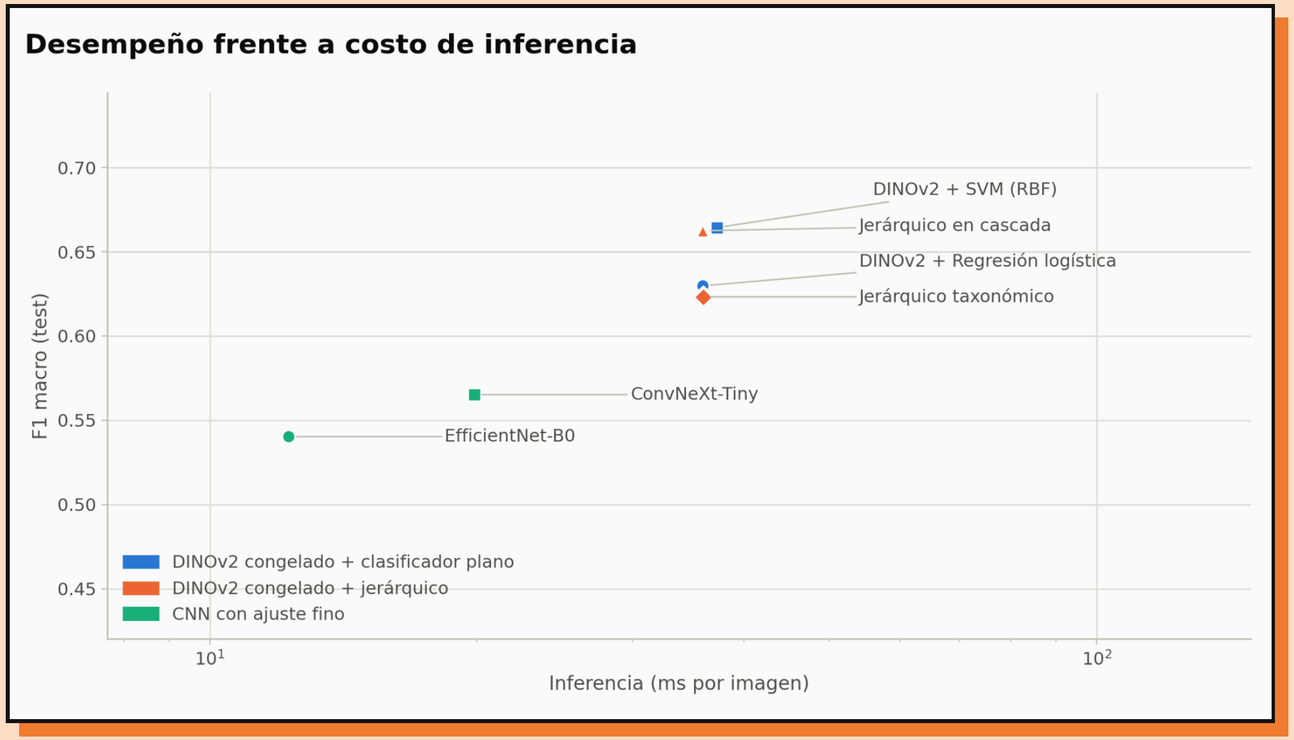
26 de 64 japonicus/koreicus terminan como albopictus

6 de 13 Anopheles terminan como Culex

15 de 93 Culiseta terminan como Culex

Aciertos: albopictus 678 de 692 · Culex 672 de 684

COSTO DE ENTRENAMIENTO



1.9 min — DINOv2 + SVM, el mejor

8.7 min — EfficientNet-B0, 6 épocas

17.6 min — ConvNeXt-Tiny, 3 épocas

Más ~6 min, una sola vez, para extraer las características de DINOv2. Inferencia: 36–37 ms por imagen contra 12–20 ms en las CNN.

ACUERDO ENTRE LOS 6 MODELOS

PROMEDIO DE LOS 6

0.672

F1 macro al promediar las probabilidades de los seis modelos. Mejor modelo solo: 0.664.

Exactitud balanceada 0.691 · exactitud 0.921

FOTOS DE PRUEBA SEGÚN EL ACUERDO



98.3 %

de aciertos cuando los seis coinciden

63.5 %

de aciertos por modelo cuando discrepan

En el promedio, aegypti sigue en F1 0.00.

LA APP: SUBE UNA FOTO

1 **CÓMO FUNCIONA**
El flujo detector, recorte y clasificadores, y los hallazgos.

2 **CLASIFICAR UNA IMAGEN**
Sube una foto, elige uno, varios o todos los modelos y mira el consenso.

3 **EXPLORAR LOS DATOS**
Distribución de clases, variables del conjunto limpio y recortes por clase.

4 **RENDIMIENTO**
Gráficas interactivas con los datos de prueba; un interruptor las oculta.

PARA CORRERLA

```
streamlit run app/streamlit_app.py
```

POR DENTRO

Foto, detector YOLOv8n, recorte con 15 % de margen, seis clasificadores y consenso. Todo corre en local.

OBJETIVOS CUMPLIDOS

GENERAL	Un sistema de dos etapas, detector y clasificador, y una app que los usa.
1 · DESBALANCE	Medido en 98 : 1 y mitigado con partición estratificada, pesos de clase y sobremuestreo.
2 · VARIABILIDAD	El mosquito ocupa 7.3 % de la foto (mediana): recorte con margen y aumento de datos.
3 · MODELO BASE	EfficientNet-B0 dio 0.540 de F1 macro; el mejor modelo llegó a 0.664.

DINOv2 + SVM: F1 macro 0.664 en 1.9 min de entrenamiento. ConvNeXt-Tiny: 0.565 en 17.6 min.

LÍMITES Y PRÓXIMOS PASOS

LÍMITES

Aegypti tiene solo 7 fotos de prueba: sus métricas cambian mucho con un solo acierto.

El detector no alcanza IoU 0.75 en 16.7 % de las fotos de prueba.

Las CNN se entrenaron poco (3 y 6 épocas) en una GPU de 4 GB.

SIGUIENTES PASOS

Más fotos de las clases raras: la literatura sugiere más de 300 por clase (Kittichai et al., 2021).

Medir el sistema completo con las cajas que predice el detector.

Entrenar las CNN más épocas, con más memoria de GPU.

REFERENCIAS 1 / 2

Buda, M., Maki, A., & Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, *106*, 249–259. https://doi.org/10.1016/j.neunet.2018.07.011

Kittichai, V., Pengsakul, T., Chumchuen, K., Samung, Y., Sriwichai, P., Phatthamolrat, N., Tongloy, T., Jaksukam, K., Chuwongin, S., & Boonsang, S. (2021). Deep learning approaches for challenging species and gender identification of mosquito vectors. *Scientific Reports*, *11*, Article 4838. https://doi.org/10.1038/s41598-021-84219-4

Mosquito Alert Team, & AIcrowd. (2023). *MosquitoAlert Challenge 2023* [Descripción del reto y conjunto de datos]. AIcrowd. https://www.aicrowd.com/challenges/mosquitoalert-challenge-2023

Motta, D., Santos, A. Á. B., Machado, B. A. S., Ribeiro-Filho, O. G. V., Camargo, L. O. A., Valdenegro-Toro, M. A., Kirchner, F., & Badaró, R. (2020). Optimization of convolutional neural network hyperparameters for automatic classification of adult mosquitoes. *PLOS ONE*, *15*(7), Article e0234959. https://doi.org/10.1371/journal.pone.0234959

REFERENCIAS 2 / 2

Ong, S.-Q., Ahmad, H., Nair, G., Isawasan, P., & Majid, A. H. A. (2021). Implementation of a deep learning model for automated classification of Aedes aegypti (Linnaeus) and Aedes albopictus (Skuse) in real time. *Scientific Reports*, *11*, Article 9908. https://doi.org/10.1038/s41598-021-89365-3

Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., … Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. https://doi.org/10.48550/arXiv.2304.07193

Silla, C. N., Jr., & Freitas, A. A. (2011). A survey of hierarchical classification across different application domains. *Data Mining and Knowledge Discovery*, *22*(1–2), 31–72. https://doi.org/10.1007/s10618-010-0175-9

Terven, J., Córdova-Esparza, D.-M., & Romero-González, J.-A. (2023). A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Machine Learning and Knowledge Extraction*, *5*(4), 1680–1716. https://doi.org/10.3390/make5040083

LIVE DEMO

01

SUBIR UNA FOTO

Una imagen de celular con un mosquito

02

ELEGIR MODELOS

Uno, varios o los seis

03

LEER EL CONSENSO

Clase predicha y grado de acuerdo

```
streamlit run app/streamlit_app.py
```

github.com/C3AC/Proyecto-2